

Fecha: 18-08-2026

ACIF104

Sumativa 2: Tercera fase del proyecto.

“Clasificación del Segmento de Precio de Vehículos Usados”.

Nombre: Gabriel Jara Rivas.

Matías Lillo Yévenes.

Nicolás Duarte Maldonado.

Nicolás Navarrete Caro.

Curso: 202615.2404 | APRENDIZAJE DE MÁQUINA | ACIF104.

Índice

1.	Problemática	1
1.1.	Contexto y relevancia	1
1.2.	Formulación del problema	2
1.3.	Requisitos iniciales del proyecto.....	2
2.	Metodología	2
2.1.	Fases metodológicas.....	2
2.2.	Plan de Trabajo	3
3.	Desarrollo del proyecto	4
3.1.	Análisis exploratorio de datos.....	4
3.2.	Selección de técnicas candidatas.....	5
3.3.	Comparación de técnicas	6
3.4.	Requisitos del proyecto	7
3.5.	Selección de la arquitectura	7
3.6.	Refinamiento de Random Forest y balanceo.....	8
3.7.	Desarrollo del frontend y backend	9
4.	Evaluación de los resultados.....	10
5.	Limitaciones	12
6.	Propuesta de Mejoras	13
7.	Conclusión	13
8.	Código fuente en GitHub.....	13
9.	Referencias bibliográficas	14

1. Problemática

En esta sección se describe la problemática que motiva el proyecto, se analiza su relevancia a partir de antecedentes recientes y se formula como una tarea de clasificación multiclase. Además, se establecen los requisitos iniciales y el alcance de la solución propuesta.

1.1. Contexto y relevancia

El mercado de vehículos usados constituye un entorno de alta complejidad para la determinación de precios. A diferencia de los vehículos nuevos, cuyo valor inicial es establecido por el fabricante, el precio de un vehículo usado depende de atributos heterogéneos —antigüedad, kilometraje, condición, marca, carrocería y equipamiento— que interactúan de forma no lineal. Esta situación genera incertidumbre para compradores y vendedores, además de asimetrías de información que dificultan reconocer publicaciones sobrevaloradas o subvaloradas.

La literatura reciente demuestra que el aprendizaje automático puede mejorar la estimación del valor de reventa, aunque sus resultados deben interpretarse considerando las características de cada estudio. Bergmann y Feuerriegel (2025), por ejemplo, obtuvieron mejoras al incorporar información granular sobre el equipamiento del vehículo en un conjunto de 92.239 transacciones. Sin embargo, ese resultado no es directamente transferible al presente proyecto, ya que `vehicles_us.csv` contiene información más limitada sobre equipamiento y proviene exclusivamente del mercado estadounidense. En consecuencia, su estudio respalda la relevancia de enriquecer los atributos disponibles, pero también advierte que la capacidad predictiva depende de la cobertura y calidad de los datos.

Li (2024) y Qian (2023) reportan buenos resultados mediante Random Forest y XGBoost en la predicción de precios de vehículos usados. No obstante, ambos trabajos formulan principalmente el problema como regresión y evalúan el desempeño mediante métricas como el coeficiente de determinación. El presente proyecto adopta una formulación diferente: clasificación multiclase por segmento de precio. Por ello, esos antecedentes justifican la selección inicial de modelos basados en árboles, pero sus métricas no son directamente comparables con el F1-macro utilizado en este estudio.

Esta elección también es coherente con el análisis comparativo de Grinsztajn, Oyallon y Varoquaux (2022), quienes evaluaron modelos neuronales y modelos basados en árboles en múltiples conjuntos tabulares y concluyeron que estos últimos continúan siendo especialmente competitivos en datos tabulares de tamaño medio. Sin embargo, su estudio no aborda específicamente el mercado automotor. En este proyecto, su conclusión se considera una hipótesis por contrastar, no una garantía de que Random Forest o XGBoost superarán necesariamente a las redes neuronales en `vehicles_us.csv`.

La distribución de la variable objetivo presenta además un desbalance importante entre los tres segmentos. Chen et al. (2024) señalan que no existe una única técnica de balanceo superior en todos los contextos y que su efectividad depende de la distribución y del clasificador utilizado. Por esta razón, el proyecto compara datos sin balanceo, ponderación de clases, SMOTE y submuestreo aleatorio dentro del proceso de entrenamiento, sin aplicar remuestreo sobre los conjuntos de validación y prueba. De este contraste se desprende que la relevancia del proyecto no se limita a obtener un modelo con buen desempeño: también busca identificar las variables asociadas a cada segmento, controlar el efecto del desbalance y reconocer los límites de generalización a otros mercados o periodos.

1.2. Formulación del problema

A partir del conjunto de datos `vehicles_us.csv`, compuesto originalmente por 51.525 avisos de vehículos usados publicados en Estados Unidos, se plantea una tarea de clasificación multiclase: dados los atributos disponibles de un vehículo, predecir el segmento de precio al que pertenece.

Antes de construir la variable objetivo se aplica el proceso de limpieza definido en `preprocessing.py`. Este elimina precios inferiores a USD 500 o superiores a USD 300.000, descarta años de fabricación anteriores a 1980 e imputa valores faltantes o inválidos en variables como año, kilometraje, cilindros, tracción y color. Como resultado, el conjunto utilizado para el modelado queda compuesto por 50.267 registros.

La variable objetivo se define mediante dos umbrales: Económico para precios inferiores a USD 5.000, Medio para precios entre USD 5.000 y USD 20.000, y Premium para precios superiores a USD 20.000. La distribución resultante es de 11.746 vehículos Económicos (23,4 %), 29.856 vehículos del segmento Medio (59,4 %) y 8.665 vehículos Premium (17,2 %).

Esta distribución confirma un desbalance relevante, debido principalmente al predominio del segmento Medio. En consecuencia, la exactitud global no resulta suficiente para evaluar los modelos, ya que podría ocultar un desempeño deficiente en las clases menos representadas. La pregunta rectora se formula así: ¿qué características de un vehículo usado permiten clasificarlo en un segmento de precio y qué estrategia de modelado ofrece el mejor equilibrio de desempeño entre las tres clases?

1.3. Requisitos iniciales del proyecto

- **Objetivo funcional:** clasificar un vehículo en uno de los tres segmentos definidos mediante los umbrales de USD 5.000 y USD 20.000 a partir de sus atributos.
- **Explicabilidad:** identificar globalmente las variables asociadas a las predicciones y presentar al usuario factores comprensibles derivados del análisis de explicabilidad.
- **Manejo del desbalance:** comparar técnicas de balanceo y mantener un desempeño adecuado en las clases menos representadas, sin contaminar los conjuntos de validación y prueba.
- **Operacionalización:** exponer la solución mediante una interfaz web y una API con capacidad de predicción y monitoreo básico.
- **Métrica principal:** utilizar F1-macro como métrica principal, complementada con accuracy, precisión y recall por clase.

2. Metodología

El proyecto se desarrolló siguiendo una metodología iterativa basada en las fases clásicas de un proyecto de ciencia de datos (Géron, 2022), organizadas de la siguiente manera:

2.1. Fases metodológicas

- **Análisis exploratorio de datos (EDA):** caracterización de las variables, evaluación de calidad (completitud, consistencia y correctitud), detección de valores atípicos y estudio de correlaciones y patrones.
- **Selección de técnicas:** elección fundamentada de algoritmos de aprendizaje supervisado, incluyendo modelos clásicos de machine learning y arquitecturas de deep learning.
- **Diseño de la arquitectura:** definición de la ingeniería de características, la codificación de variables y la topología de las redes neuronales.
- **Implementación, validación y evaluación:** entrenamiento con partición estratificada train/validación/test, análisis de técnicas de balanceo, evaluación con datos no vistos e interpretación mediante SHAP.

2.2. Plan de Trabajo

La Tabla 1 vincula cada tarea con una persona responsable, un plazo y el objetivo del proyecto al que contribuye.

Tarea	Responsable	Plazo	Objetivo asociado
Limpieza y análisis exploratorio de datos	Gabriel Jara	Semana 1	Evaluar calidad de datos, variables y patrones
Ingeniería de características	Matías Lillo	Semana 1	Preparar las variables utilizadas por los modelos
Modelos de ML y comparación	Nicolás Duarte	Semana 2	Seleccionar técnicas tradicionales de clasificación
Modelos de DL y análisis de convergencia	Nicolás Navarrete	Semana 2	Comparar arquitecturas neuronales con los modelos tradicionales
Evaluación de técnicas de balanceo	Gabriel Jara	Semana 3	Mejorar el desempeño en las clases minoritarias
Análisis de explicabilidad global con SHAP	Matías Lillo	Semana 3	Identificar las variables asociadas con las predicciones
Desarrollo inicial del frontend y backend	Nicolás Duarte	Semana 3	Operacionalizar el modelo mediante una interfaz web y una API
Redacción y revisión de la primera entrega	Todo el equipo	Semana 4	Entregable Sumativa 1
Análisis de la retroalimentación y auditoría de resultados	Todo el equipo	Semana 5	Identificar inconsistencias entre informe, código y resultados
Regeneración del EDA y corrección de la variable objetivo	Gabriel Jara	Semana 5	Alinear la Figura 1, conteos y porcentajes con el pipeline real
Refinamiento y barrido de hiperparámetros de Random Forest	Nicolás Duarte	Semana 6	Justificar la cantidad de árboles, profundidad, tiempo y tamaño
Corrección de callbacks y validación de modelos DL	Nicolás Navarrete	Semana 6	Evitar la reutilización de estado de EarlyStopping
Revisión del análisis SHAP y variables redundantes	Matías Lillo	Semana 7	Declarar el uso del modelo sustituto y reconocer la redundancia entre model_year y age
Actualización del frontend, backend y monitoreo	Nicolás Duarte	Semana 7	Diferenciar probabilidades estimadas, orientación heurística y explicabilidad local
Reentrenamiento y evaluación reproducible del modelo final	Gabriel Jara	Semana 8	Generar métricas, matriz de confusión y modelo comprimido
Actualización de scripts, dependencias y README	Nicolás Navarrete	Semana 8	Garantizar instalación, ejecución y trazabilidad del repositorio
Validación cruzada entre código, figuras e informe	Todo el equipo	Semana 9	Comprobar la correspondencia de métricas, tablas, figuras y conclusiones
Redacción y revisión final del informe	Todo el equipo	Semana 9	Entregable Sumativa 2

Tabla 1. Plan de trabajo grupal y actividades de mejora desarrolladas entre las sumativas 1 y 2.

3. Desarrollo del proyecto

En esta sección se presenta el desarrollo técnico del proyecto, incluyendo el análisis y preparación de los datos, la comparación de las técnicas candidatas, la selección y refinamiento del modelo y su implementación mediante una aplicación web.

3.1. Análisis exploratorio de datos

El archivo original contiene 51.525 registros y 13 variables. Las variables numéricas son price, model_year, cylinders, odometer y days_listed; las variables categóricas son model, condition, fuel, transmission, type y paint_color. Además, is_4wd se trata como una variable binaria y date_posted como una variable temporal. Después de aplicar el pipeline de limpieza, el conjunto utilizado para el modelado contiene 50.267 observaciones.

Compleitud, consistencia y correctitud. En los datos originales se observaron ausencias en is_4wd (50,4 %), paint_color (18,0 %), odometer (15,3 %), cylinders (10,2 %) y model_year (7,0 %). La ausencia de is_4wd se interpretó como no 4x4; paint_color se transformó en la categoría unknown y las variables numéricas se imputaron mediante la mediana por modelo y, cuando fue necesario, la mediana global. También se filtraron precios fuera del intervalo USD 500–300.000 y años anteriores a 1980; odómetros iguales a cero o superiores a 400.000 se trataron como inválidos antes de imputar. El resultado no conserva valores faltantes en las variables empleadas por el modelo.

Estadísticas descriptivas. La Tabla 2 resume tendencia central, dispersión y rango en el dataset limpio. El precio mantiene un sesgo positivo: la media (USD 12.353) supera a la mediana (USD 9.500), mientras el máximo de USD 300.000 confirma una cola derecha extensa.

Variable	Media	Desv. estándar	Mínimo	Mediana	Máximo
Precio (USD)	12.353,12	9.824,64	500	9.500	300.000
Año del modelo	2.009,84	5,53	1.980	2.011	2.019
Cilindros	6,1	1,64	3	6	12
Odómetro	116.884,89	57.834,92	1	117.434,50	400.000
Días de publicación	39,56	28,21	0	33	271

Tabla 2. Estadísticas descriptivas del conjunto de datos después de la limpieza.

Variables categóricas. La Tabla 3 caracteriza su cardinalidad y categoría modal. Fuel y transmission están fuertemente concentradas en gas y automatic, respectivamente, mientras type y paint_color presentan mayor diversidad. Model posee 100 categorías, lo que justifica el uso de codificación one-hot en los modelos clásicos y embeddings en una de las redes.

Variable	Cardinalidad	Categoría modal	Frecuencia	%
model	100	ford f-150	2.724	5,42
condition	6	excellent	23.793	47,33
fuel	5	gas	46.048	91,61
transmission	3	automatic	46.034	91,58
type	13	SUV	12.095	24,06
paint_color	13	white	9.816	19,53

Tabla 3. Cardinalidad y categoría modal de las variables categóricas.

Variables binaria y temporal. Después de la limpieza, la variable `is_4wd` presenta 24.815 vehículos con tracción 4×4 (49,37 %) y 25.452 sin tracción 4×4 (50,63 %). Esta distribución prácticamente equilibrada indica que la tracción se encuentra suficientemente representada en ambos grupos y puede utilizarse como característica predictiva sin requerir un tratamiento especial por desbalance. Por su parte, `date_posted` abarca desde el 1 de mayo de 2018 hasta el 19 de abril de 2019, correspondiente a un periodo de 353 días. La cobertura temporal es inferior a un año completo, por lo que el modelo representa las condiciones del mercado observadas durante ese intervalo y no permite evaluar cambios de precio de largo plazo.

Valores atípicos y patrones. El precio se relaciona positivamente con `model_year` ($r = 0,52$) y negativamente con `odometer` ($r = -0,45$); `days_listed` no presenta asociación lineal relevante. La Figura 1 emplea el mismo dataset limpio y los mismos cortes del target que el pipeline: Económico, 11.746 casos (23,4 %); Medio, 29.856 (59,4 %); y Premium, 8.665 (17,2 %). Por tanto, la figura evidencia el predominio real de la clase Medio.




Figura 1. Panorama del análisis exploratorio después de la limpieza: distribución del precio, relación precio-odómetro, correlaciones y distribución real del target.

3.2. Selección de técnicas candidatas

La selección de técnicas se fundamentó en la revisión de trabajos previos. Para los datos tabulares y heterogéneos de este problema, la literatura converge en que los métodos basados en árboles suelen ser los más efectivos. Breiman (2001) introdujo el Random Forest, un ensamble de árboles que reduce la varianza mediante agregación; Chen y Guestrin (2016) propusieron XGBoost, un algoritmo de potenciación del gradiente que domina numerosas competencias de datos estructurados. Diversos estudios de predicción de precios de autos usados (Li, 2024; Qian, 2023; Bergmann y Feuerriegel, 2025) reportan a estos modelos como los de mejor desempeño.

Por exigencia del proyecto se incorpora además un modelo neuronal de aprendizaje profundo. Sin embargo, la evidencia reciente advierte que en datos tabulares las redes neuronales no siempre superan a los árboles: Grinsztajn et al. (2022) y Shwartz-Ziv y Armon (2022) demuestran empíricamente que los modelos basados en árboles mantienen ventaja en la mayoría de los conjuntos tabulares, debido a sus sesgos inductivos frente a características heterogéneas. Se incorpora el perceptrón multicapa (MLP) precisamente para contrastar esta hipótesis en el contexto del proyecto. Las técnicas seleccionadas son, por tanto:

- **Regresión Logística** — baseline lineal, interpretable.
- **Random Forest** — ensamble de árboles, robusto ante outliers.
- **XGBoost** — potenciación del gradiente, alto rendimiento.
- **Redes neuronales MLP** — tres arquitecturas de deep learning (ver 3.5).

3.3. Comparación de técnicas

Se compararon tres técnicas de machine learning y tres arquitecturas de deep learning sobre el conjunto de validación, empleando F1-macro como métrica principal por su robustez frente al desbalance. La Tabla 4 y la Figura 2 resumen los resultados.

Modelo	Tipo	Accuracy	F1-macro
Regresión Logística	ML	0,758	0,751
Random Forest	ML	0,862	0,846
XGBoost	ML	0,849	0,831
MLP Shallow	DL	0,805	0,797
MLP Profunda	DL	0,805	0,797
MLP Embeddings	DL	0,809	0,801

Tabla 4. Resumen de resultados de la Comparación de F1-macro entre técnicas de Machine Learning y Deep Learning.




Figura 2. Comparación de F1-macro entre técnicas de Machine Learning y Deep Learning.

Los resultados confirman la hipótesis planteada: Random Forest obtiene el mejor desempeño en validación (F1-macro 0,846), por encima de XGBoost y de las tres arquitecturas neuronales. El empate aparente entre MLP Shallow y MLP Profunda no es un error de transcripción: sus valores sin redondear fueron 0,8048 y 0,8046. Que arquitecturas de capacidades tan distintas converjan al mismo desempeño sugiere que el límite se relaciona más con la información disponible en las variables que con la profundidad de la red.

La comparación debe interpretarse con una salvedad: no constituye un experimento de balanceo estrictamente controlado. Regresión Logística y Random Forest utilizaron `class_weight=balanced`, XGBoost no incorporó pesos y los MLP se entrenaron con pesos de clase. En consecuencia, la tabla permite seleccionar una familia prometedora, pero no atribuir toda la diferencia exclusivamente al algoritmo. El efecto del balanceo se estudia por separado sobre Random Forest.

Restricciones computacionales. Los modelos clásicos admiten entrenamiento paralelo en CPU, mientras los MLP requieren TensorFlow, mayor memoria para matrices densas y entrenamiento por épocas. Las ejecuciones originales no instrumentaron tiempos comparables para las seis técnicas; por ello no se informan duraciones retrospectivas. Esta ausencia se reconoce como limitación experimental y se complementa con el barrido reproducible de Random Forest presentado en la sección de refinamiento.

3.4. Requisitos del proyecto

A partir del alcance definido se identifican los siguientes requisitos, vinculados explícitamente a los objetivos:

Tipo	Requisito	Cómo se satisface
Funcional	Clasificar el segmento de precio	Modelo RF + SMOTE expuesto vía API
Funcional	Entregar probabilidades por clase	Salida <code>predict_proba</code> en <code>/predict</code>
No funcional	Usabilidad	Interfaz web con formulario guiado
No funcional	Explicabilidad	SHAP global sobre RF sustituto + reglas heurísticas en la interfaz
No funcional	Escalabilidad	Backend FastAPI, modelo serializado
No funcional	Seguridad	Validación de entradas con Pydantic
No funcional	Confiabilidad	Partición estratificada de entrenamiento, validación y prueba, con evaluación final sobre datos no utilizados durante el entrenamiento.
No funcional	Monitoreabilidad	Endpoint <code>/metrics</code> con uso y latencia


Tabla 5. Tipo, requisitos y su satisfacción.

3.5. Selección de la arquitectura

Siguiendo los fundamentos de Goodfellow et al. (2016), se evaluaron tres arquitecturas de perceptrón multicapa, todas con salida softmax de tres neuronas (una por clase) y entrenadas con la función de pérdida de entropía cruzada categórica y el optimizador Adam. Se aplicó early stopping para evitar el sobreajuste.

- **MLP Shallow:** Una capa oculta de 64 neuronas con activación ReLU. Baseline neuronal.
- **MLP Profunda:** Tres capas ocultas (128-64-32) con normalización por lotes (BatchNorm) y regularización por Dropout (0,3).
- **MLP con Embeddings:** Capas de embedding para las variables categóricas de alta cardinalidad (marca, tipo), concatenadas con las numéricas antes de las capas densas.

El análisis de convergencia (Figura 3) muestra que las tres arquitecturas alcanzan una meseta en pocas épocas. La red con embeddings obtuvo el mayor F1-macro entre las MLP (0,801), aunque la diferencia es pequeña. En una ejecución reproducible, cada llamada a fit debe crear su propia instancia de EarlyStopping; compartir el callback entre modelos puede arrastrar el mejor `val_loss` y alterar la época de detención. Esta precaución no cambia la superioridad observada de Random Forest, pero debe aplicarse en futuras réplicas.



3.6. Refinamiento de Random Forest y balanceo

Para respaldar la decisión de diseño se realizó un barrido de hiperparámetros sobre el Random Forest base con `class_weight="balanced"`, variando `n_estimators` y `max_depth` sobre la misma partición de validación. El experimento se ejecutó en Windows, utilizando Python 3.12.10 y procesamiento en CPU sobre un Intel Core Ultra 7 155U, compuesto por 12 núcleos y 14 procesadores lógicos, con 15,5 GB de memoria RAM. Los tiempos son referenciales del entorno utilizado y no se comparan directamente con las redes neuronales, cuyos entrenamientos originales no fueron cronometrados.

Árboles	Profundidad	F1-macro	Recall Premium	Recall Económico	Tiempo (s)	Tamaño (MB)
100	20	0,836	0,855	0,763	6,6	20,1
100	Sin límite	0,846	0,835	0,732	8,8	28,4
200	20	0,839	0,856	0,768	13,3	40,3
200	Sin límite	0,846	0,837	0,729	15,9	56,7
300	20	0,839	0,857	0,767	16,7	60,6
300	Sin límite	0,846	0,835	0,727	21,3	85,2

Tabla 6. Barrido de hiperparámetros del Random Forest base en validación.

El barrido muestra que aumentar de 100 a 200 o 300 árboles sin limitar la profundidad no mejora el F1-macro a tres decimales, que se mantiene en 0,846, pero incrementa progresivamente el tiempo de entrenamiento y el tamaño serializado. Entre estas configuraciones, el modelo de 100 árboles sin límite resulta el más eficiente, con un tiempo de 8,8 segundos y un tamaño de 28,4 MB. El modelo final conserva 200 árboles para mantener la reproducción exacta de los resultados previamente reportados; no obstante, la configuración de 100 árboles sin límite constituye una alternativa operacional que debería revalidarse en combinación con SMOTE. Limitar la profundidad a 20 reduce el tamaño del modelo y aumenta ligeramente el recall de las clases Premium y Económico, aunque disminuye el F1-macro entre 0,007 y 0,010 puntos.

El conjunto se particionó de forma estratificada en 70 % entrenamiento, 15 % validación y 15 % prueba, preservando la proporción de clases en cada subconjunto. Dado el desbalance (ratio 3,4× entre la clase mayoritaria y la minoritaria), se analizó el efecto de tres técnicas de balanceo sobre el Random Forest, conforme a las recomendaciones de Chawla et al. (2002) y Chen et al. (2024). Los resultados se presentan en la Tabla 7 y la Figura 4.

Técnica	F1-macro	Recall Premium	Recall Económico
Sin balanceo	0,846	0,842	0,733
Class weights	0,844	0,832	0,726
SMOTE	0,847	0,865	0,773
Undersampling	0,811	0,927	0,844

Tabla 7. Técnicas, F1-macro, Recall Premium y Recall Económico.




Figura 4. Efecto de las técnicas de balanceo sobre el desempeño del Random Forest.

El sobremuestreo sintético SMOTE (Chawla et al., 2002; Elreedy et al., 2024) ofrece el mejor compromiso: incrementa el recall de las clases minoritarias y mantiene el F1-macro respecto del modelo sin balanceo.

El submuestreo maximiza el recall de la clase Premium (0,927) pero degrada el F1-macro al descartar información de la clase mayoritaria, ilustrando el clásico compromiso del balanceo. La ponderación de clases apenas modifica el desempeño base. En consecuencia, el modelo final se define como Random Forest combinado con SMOTE.

3.7. Desarrollo del frontend y backend

La solución se operacionalizó mediante un backend FastAPI y una interfaz web. El endpoint /predict valida las entradas con Pydantic, construye las mismas características esperadas por el pipeline y devuelve segmento y probabilidades. Los endpoints /health y /metrics informan disponibilidad, número de predicciones, distribución de clases y latencias media y p95.

La explicación mostrada en la interfaz no corresponde a valores SHAP por instancia. Es una explicación heurística basada en reglas sobre año, kilometraje, tracción, cilindros y carrocería, variables seleccionadas a partir del análisis global. Por tanto, orienta al usuario sobre factores plausibles, pero no debe interpretarse como atribución local del clasificador. La Figura 5 presenta el flujo completo de predicción y monitoreo.




Figura 5. Interfaz del sistema mostrando una predicción, sus probabilidades estimadas, la orientación heurística y el panel de monitoreo.

4. Evaluación de los resultados

El modelo final (Random Forest + SMOTE) se evaluó sobre el conjunto de prueba, compuesto por 7.541 vehículos no utilizados durante el entrenamiento. Los resultados se resumen en la Tabla 8.

Segmento	Precisión	Recall	F1-score	Soporte
Económico	0,796	0,780	0,788	1.762
Medio	0,879	0,885	0,882	4.479
Premium	0,868	0,872	0,870	1.300
Global (macro)	0,847	0,845	0,846	—

Tabla 8. Resumen del modelo final.

La exactitud global alcanza 0,858 y el F1-macro 0,846, valores consistentes con el desempeño observado durante la validación. La matriz de confusión de la Figura 6 muestra que la mayor parte de los errores ocurre entre segmentos vecinos. Se registran 381 vehículos Económicos clasificados como Medio y 350 vehículos del segmento Medio clasificados como Económico. Asimismo, 167 vehículos Medios fueron clasificados como Premium y 164 vehículos Premium como Medio. Las confusiones extremas Económico↔Premium suman nueve casos al considerar ambas direcciones de la matriz: seis vehículos Económicos clasificados como Premium y tres Premium clasificados como Económico. Por tanto, los errores extremos continúan siendo poco frecuentes, aunque estos resultados no demuestran por sí solos ausencia de sobreajuste ni garantizan la generalización fuera del dataset.

El modelo también entrega probabilidades para cada segmento. Sin embargo, estas probabilidades expresan la distribución estimada por el clasificador y no deben interpretarse automáticamente como niveles de confianza perfectamente calibrados. Desde una perspectiva probabilística, la calidad de estas estimaciones debe comprobarse mediante procedimientos específicos de calibración y métricas como la pérdida logarítmica o el Brier score (Murphy, 2018). Como estas pruebas no forman parte del alcance actual, las probabilidades presentadas por la aplicación deben considerarse orientativas.




Figura 6. Matriz de confusión del modelo final sobre el conjunto de prueba.

Interpretabilidad. La interpretabilidad global se abordó mediante SHAP, método propuesto por Lundberg y Lee (2017) para atribuir la contribución de las variables a las predicciones de un modelo. El análisis SHAP de las Figuras 7 y 8 se calculó sobre un Random Forest sustituto de 120 árboles y profundidad máxima 14, entrenado con SMOTE para reducir el costo computacional de la explicación. Por ello, describe un modelo representativo y cercano al final, no exactamente el objeto serializado usado por la API. Model_year y age encabezan el ranking, pero contienen la misma información porque $\text{age} = 2019 - \text{model_year}$; SHAP reparte entre ambas el crédito de un único hallazgo asociado a la antigüedad. Luego aparecen kilometraje, tracción 4x4, cilindros y carrocería. Estas asociaciones son coherentes con el dominio, aunque no demuestran causalidad.




Figura 7. Importancia global de las variables según valores SHAP.




Figura 8. Variables que empujan la clasificación hacia cada segmento de precio.

5. Limitaciones

El modelo se entrenó con avisos del mercado estadounidense correspondientes a un periodo y una plataforma específicos. Sus métricas internas no garantizan el mismo comportamiento en Chile u otros mercados. Además, los umbrales fijos de USD 5.000 y USD 20.000 no se ajustan por inflación, categoría del vehículo ni cambios temporales. La confusión Económico↔Medio observada en la Figura 6 es consistente con vehículos situados cerca de esos límites.

También existen limitaciones técnicas: `model_year` y `age` son redundantes; SHAP se calculó sobre un modelo sustituto; la interfaz entrega reglas heurísticas y no atribuciones locales; la comparación inicial no igualó el tratamiento del desbalance entre todas las técnicas; y los tiempos de las arquitecturas neuronales no se instrumentaron. Estas restricciones delimitan el alcance de las conclusiones.

6. Propuesta de Mejoras

Como primera línea de mejora, se propone optimizar Random Forest y XGBoost mediante validación cruzada estratificada y búsqueda bayesiana de hiperparámetros, registrando F1-macro, métricas por clase, calibración, tiempo de entrenamiento y tamaño del modelo. El barrido presentado en la Tabla 6 indica que una configuración de 100 árboles puede reducir el costo computacional sin una pérdida apreciable de desempeño. Asimismo, se recomienda calibrar las probabilidades mediante escalado de Platt o calibración isotónica y evaluar profundidades acotadas, con el propósito de que las probabilidades informadas representen de manera más fiable la frecuencia real de aciertos del modelo, especialmente en predicciones extremas.

Como segunda línea de mejora, se propone eliminar una de las variables redundantes, `model_year` o `age`, reentrenar el modelo y recalcular SHAP directamente sobre la configuración final. Esto permitiría reemplazar las orientaciones heurísticas de la interfaz por explicaciones locales asociadas a cada predicción. Finalmente, se recomienda enriquecer el conjunto de datos con información sobre equipamiento, historial del vehículo, ubicación y condiciones del mercado, además de evaluar segmentos condicionados por tipo de carrocería y un ensamble *stacking* de Random Forest, XGBoost y MLP con embeddings.

7. Conclusión

El proyecto demuestra que Random Forest combinado con SMOTE constituye una solución adecuada para clasificar vehículos usados en los segmentos Económico, Medio y Premium. El modelo alcanzó una exactitud de 0,858 y un F1-macro de 0,846 sobre un conjunto de prueba independiente de 7.541 registros, con valores de recall de 0,780, 0,885 y 0,872 para cada segmento, respectivamente. Estos resultados muestran un desempeño consistente, aunque la clase Económico continúa siendo la más difícil de identificar.

La separación estricta del conjunto de prueba, la reproducción del pipeline y el análisis de la matriz de confusión fortalecen la validez de los resultados obtenidos. Además, la implementación web demuestra la viabilidad de operacionalizar el modelo mediante una interfaz de predicción y funciones básicas de monitoreo. Finalmente, la auditoría realizada permitió diferenciar claramente el modelo final, el modelo sustituto empleado en el análisis SHAP y el carácter heurístico de las orientaciones actuales, estableciendo mejoras concretas para avanzar hacia predicciones calibradas y explicaciones locales reales.

8. Código fuente en GitHub

El código completo del proyecto se encuentra disponible en el siguiente repositorio: https://github.com/niconvc/acif104_s9_grupo4. El repositorio está organizado en las carpetas `data` (dataset), `src` (preprocesamiento, entrenamiento de modelos, balanceo y explicabilidad), `models` (modelo serializado), `backend` (API FastAPI), `frontend` (interfaz web), `reports` (resultados y figuras) y `docs` (documentación y evidencia audiovisual). Incluye un archivo README con instrucciones de instalación y ejecución, y un archivo `requirements.txt` con las dependencias.

Como evidencia complementaria, se incluye en la carpeta `docs` el archivo `demostracion_sistema_funcional.mp4`, que presenta la operación del sistema web. El video muestra la generación de predicciones para los tres segmentos, las probabilidades estimadas, las orientaciones heurísticas, la actualización del panel de monitoreo y la validación de datos fuera de rango. En la misma carpeta se encuentra disponible el informe final en formato PDF.

El repositorio incorpora scripts reproducibles para el análisis exploratorio, el barrido de hiperparámetros y la evaluación final. La ejecución de `final_model.py` genera automáticamente el resumen de métricas, la matriz de confusión en formato CSV, la Figura 6 y el modelo serializado utilizado por el backend. El modelo se almacena localmente con compresión mediante Joblib, reduciendo su tamaño a 63,1 MB, y se excluye del repositorio mediante `.gitignore`; por tanto, debe regenerarse siguiendo las instrucciones del archivo README.

9. Referencias bibliográficas

- Bergmann, S., y Feuerriegel, S. (2025). Machine learning for predicting used car resale prices using granular vehicle equipment information. *Expert Systems with Applications*, 263, 125640. <https://doi.org/10.1016/j.eswa.2024.125640>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., y Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>
- Chen, W., Yang, K., Yu, Z., Shi, Y., y Chen, C. L. P. (2024). A survey on imbalanced learning: Latest research, applications and future directions. *Artificial Intelligence Review*, 57(6), 137. <https://doi.org/10.1007/s10462-024-10759-6>
- Elreedy, D., Atiya, A. F., y Kamalov, F. (2024). A theoretical distribution analysis of synthetic minority oversampling technique (SMOTE) for imbalanced learning. *Machine Learning*, 113(7), 4903–4923. <https://doi.org/10.1007/s10994-022-06296-4>
- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.^a ed.). O'Reilly Media.
- Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep learning*. MIT Press.
- Grinsztajn, L., Oyallon, E., y Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems*, 35, 507–520.
- Li, C. (2024). Machine learning-based models for accurate car prices prediction. *Highlights in Business, Economics and Management*, 40. <https://doi.org/10.54097/9zcpv779>
- Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- Murphy, K. P. (2018). *Machine learning: A probabilistic perspective*. MIT Press.
- Qian, T. (2023). Used car price prediction by using XGBoost. *BCP Business & Management*, 44. <https://doi.org/10.54691/bcpbm.v44i.4794>
- Shwartz-Ziv, R., y Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, 81, 84–90. <https://doi.org/10.1016/j.inffus.2021.11.011>